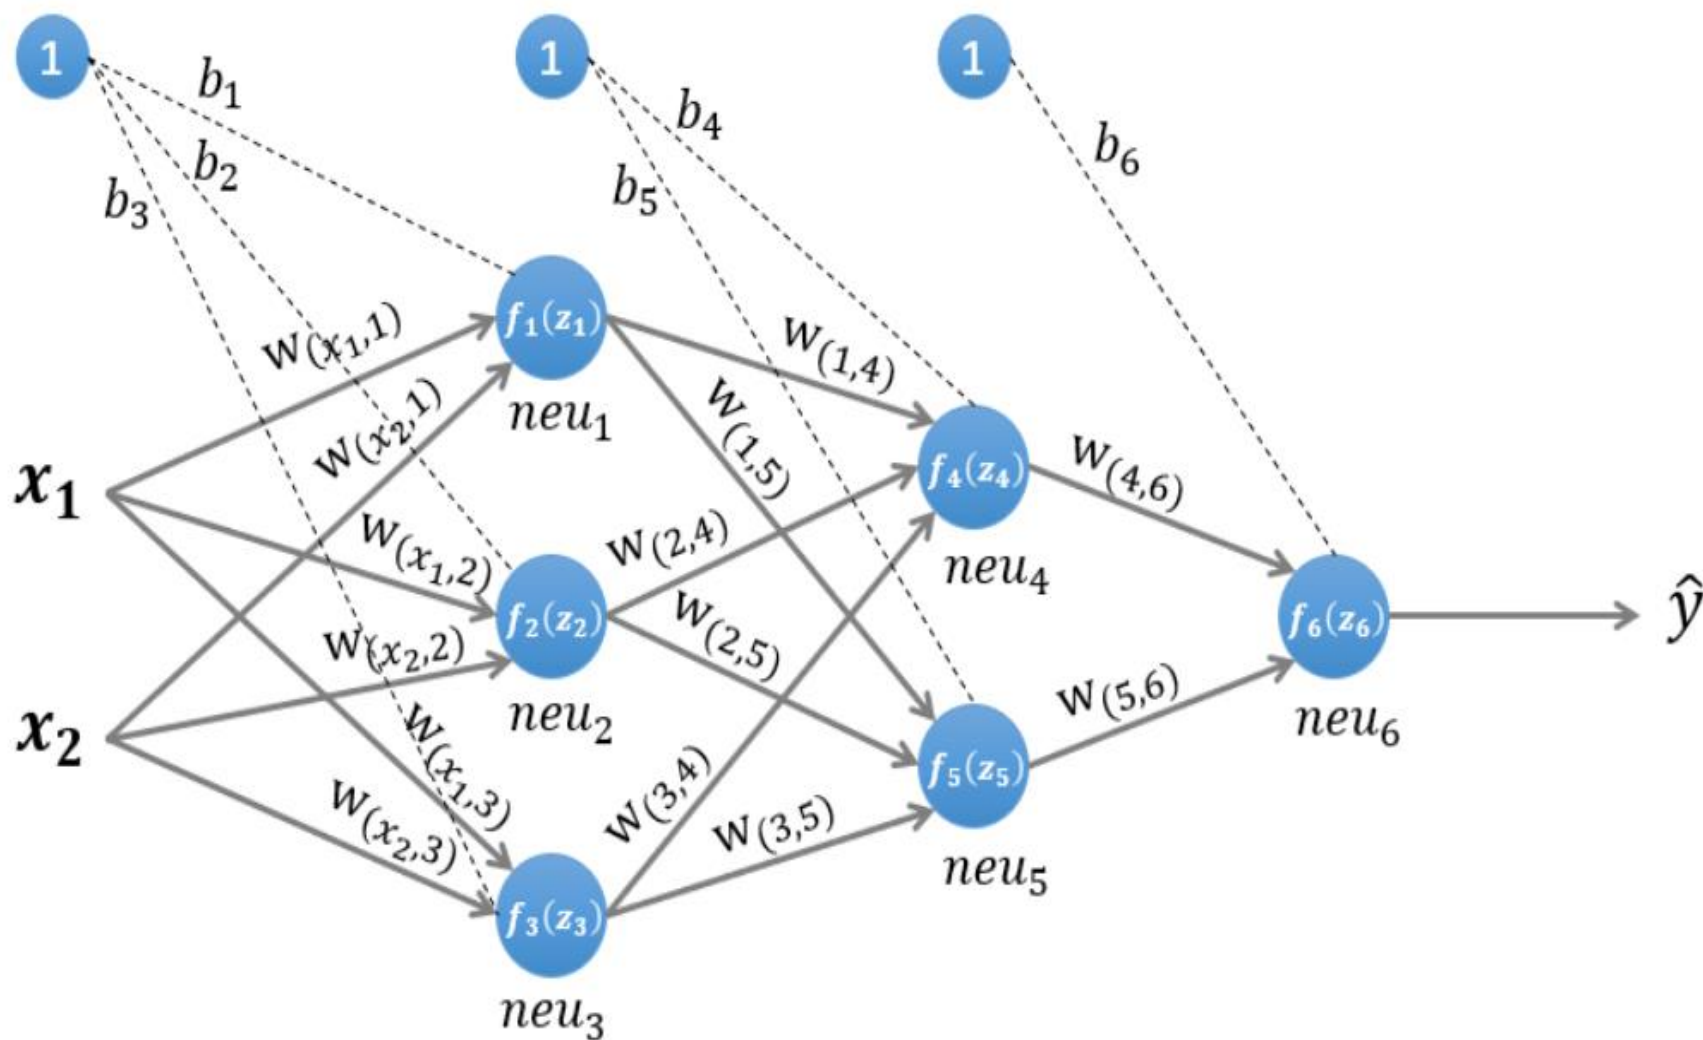


BP算法推演

训练数据: 特征个数为2

BP网络: 三层, 两个隐藏层, 一个输出层

分类问题: 二类分类



1 正向传播

输入样本: $\mathbf{x} = [x_1, x_2]^T$

第一层网络参数: $\mathbf{W}^{(1)} = \begin{bmatrix} w_{(x_1,1)} & w_{(x_2,1)} \\ w_{(x_1,2)} & w_{(x_2,2)} \\ w_{(x_1,3)} & w_{(x_2,3)} \end{bmatrix}, \mathbf{b}^{(1)} = [b_1 \quad b_2 \quad b_3]^T$


第二层网络参数:

$$\mathbf{W}^{(2)} = \begin{bmatrix} w_{(1,4)} & w_{(2,4)} & w_{(3,4)} \\ w_{(1,5)} & w_{(2,5)} & w_{(3,5)} \end{bmatrix}, \mathbf{b}^{(2)} = [b_4 \quad b_5]^T$$

第三层网络参数:

$$\mathbf{W}^{(3)} = [w_{(4,6)} \quad w_{(5,6)}], \mathbf{b}^{(3)} = [b_6]^T$$

1.1 第一层隐含层的计算



第一层有三个神经元，该层的输入为：

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)} * \mathbf{x} + \mathbf{b}^{(1)}$$

neu_1 , neu_2 , neu_3 的输入为：

$$z_1 = w_{(x_1,1)} * x_1 + w_{(x_2,1)} * x_2 + b_1$$

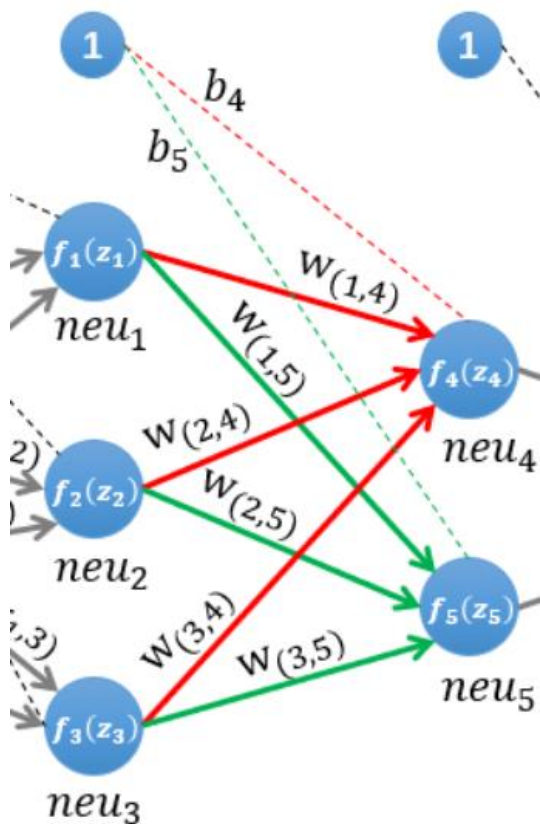
$$z_2 = w_{(x_1,2)} * x_1 + w_{(x_2,2)} * x_2 + b_2$$

$$z_3 = w_{(x_1,3)} * x_1 + w_{(x_2,3)} * x_2 + b_3$$

该层的输出为：

$$\mathbf{n}^{(1)} = [f_1(z_1) \quad f_2(z_2) \quad f_3(z_3)]^T$$

1.2 第二层隐含层的计算



第二层有两个神经元，该层的输入为：

$$\begin{aligned} \mathbf{z}^{(2)} &= \mathbf{W}^{(2)} * \mathbf{n}^{(1)} + \mathbf{b}^{(2)} \\ &= \mathbf{W}^{(2)} * [f_1(z_1) \quad f_2(z_2) \quad f_3(z_3)]^T + \mathbf{b}^{(2)} \end{aligned}$$

neu_4 和 neu_5 的输入为：


$$z_4 = w_{(1,4)} * f_1(z_1) + w_{(2,4)} * f_2(z_2) + w_{(3,4)} * f_3(z_3) + b_4$$

$$z_5 = w_{(1,5)} * f_1(z_1) + w_{(2,5)} * f_2(z_2) + w_{(3,5)} * f_3(z_3) + b_5$$

该层的输出为：

$$\mathbf{n}^{(2)} = [f_4(z_4) \quad f_5(z_5)]^T$$

1.3 输出层的计算



输出层只有一个神经元，该层的输入为：

$$\begin{aligned} \mathbf{z}^{(3)} &= \mathbf{W}^{(3)} * \mathbf{n}^{(2)} + \mathbf{b}^{(3)} \\ &= \mathbf{W}^{(3)} * [f_4(z_4) \ f_5(z_5)]^T + \mathbf{b}^{(3)} \end{aligned}$$

neu_6 的输入为：

$$z_6 = w_{(4,6)} * f_4(z_4) + w_{(5,6)} * f_5(z_5) + b_6$$

该层要解决二类分类问题，激活函数选Sigmoid函数，则神经网络的输出为：

$$\mathbf{n}^{(3)} = [f_6(z_6)]^T$$

2 反向传播

定义损失函数： $L(y, \hat{y})$ ， y 是该样本的真实类标，采用随机梯度下降法进行参数学习，计算损失函数关于神经网络各层参数（权重 \mathbf{W} 和偏置 \mathbf{b} ）的偏导数。

假设我们要对第 k 层隐藏层的参数 $W^{(k)}$ 和 $b^{(k)}$ 求偏导数，即求 $\frac{\partial L(y, \hat{y})}{\partial W^{(k)}}$ 和 $\frac{\partial L(y, \hat{y})}{\partial b^{(k)}}$ 。假设 $z^{(k)}$ 代表第 k 层

神经元的输入，即 $z^{(k)} = W^{(k)} * n^{(k-1)} + b^{(k)}$ ，其中 $n^{(k-1)}$ 为前一层神经元的输出，则根据链式法

则有：↵

$$\begin{aligned}\frac{\partial L(y, \hat{y})}{\partial W^{(k)}} &= \frac{\partial L(y, \hat{y})}{\partial z^{(k)}} * \frac{\partial z^{(k)}}{\partial W^{(k)}} \quad \text{↵} \\ \frac{\partial L(y, \hat{y})}{\partial b^{(k)}} &= \frac{\partial L(y, \hat{y})}{\partial z^{(k)}} * \frac{\partial z^{(k)}}{\partial b^{(k)}} \quad \text{↵}\end{aligned}$$

因此，我们只需要计算偏导数 $\frac{\partial L(y, \hat{y})}{\partial z^{(k)}}$ 、 $\frac{\partial z^{(k)}}{\partial W^{(k)}}$ 和 $\frac{\partial z^{(k)}}{\partial b^{(k)}}$ 。↵

2.1 计算偏导数 $\frac{\partial z^{(k)}}{\partial W^{(k)}}$

根据正向传播公式，第k层的输入与第（k-1）层的输出之间的关系为：

$$\mathbf{z}^{(k)} = \mathbf{W}^{(k)} * \mathbf{n}^{(k-1)} + \mathbf{b}^{(k)}$$

则

$$\frac{\partial \mathbf{z}^{(k)}}{\partial \mathbf{W}^{(k)}} = \mathbf{n}^{(k-1)T}$$

2.2 计算偏导数 $\frac{\partial z^{(k)}}{\partial b^{(k)}}$

因为偏置 b 是一个常数项，因此偏导数的计算也很简单：

$$\frac{\partial z^{(k)}}{\partial b^{(k)}} = \begin{bmatrix} \frac{\partial (W_{1:}^{(k)} * n^{(k-1)} + b_1)}{\partial b_1} & \dots & \frac{\partial (W_{1:}^{(k)} * n^{(k-1)} + b_1)}{\partial b_m} \\ \vdots & \dots & \vdots \\ \frac{\partial (W_{m:}^{(k)} * n^{(k-1)} + b_m)}{\partial b_1} & \dots & \frac{\partial (W_{m:}^{(k)} * n^{(k-1)} + b_m)}{\partial b_m} \end{bmatrix}$$

依然以第一层隐藏层的神经元为例，则有：

$$\frac{\partial z^{(1)}}{\partial b^{(1)}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

2.3 计算偏导数 $\frac{\partial L(y, \hat{y})}{\partial z^{(k)}}$

偏导数 $\frac{\partial L(y, \hat{y})}{\partial z^{(k)}}$ 又称为误差项 (error term, 也称为“灵敏度”), 一般用 δ 表示, 例如 $\delta^{(1)} = \frac{\partial L(y, \hat{y})}{\partial z^{(1)}}$

是第一层神经元的误差项, 其值的大小代表了第一层神经元对于最终总误差的影响大小。

根据第一节的前向计算, 我们知道第 $k + 1$ 层的输入与第 k 层的输出之间的关系为:

$$z^{(k+1)} = W^{(k+1)} * n^{(k)} + b^{k+1}$$

又因为 $n^{(k)} = f_k(z^{(k)})$, 根据链式法则, 我们可以得到 $\delta^{(k)}$ 为:

$$\begin{aligned}\delta^{(k)} &= \frac{\partial L(y, \hat{y})}{\partial z^{(k)}} \\&= \frac{\partial n^{(k)}}{\partial z^{(k)}} * \frac{\partial z^{(k+1)}}{\partial n^{(k)}} * \frac{\partial L(y, \hat{y})}{\partial z^{(k+1)}} \\&= \frac{\partial n^{(k)}}{\partial z^{(k)}} * \frac{\partial z^{(k+1)}}{\partial n^{(k)}} * \delta^{(k+1)} \\&= f'_k(z^{(k)}) * ((W^{(k+1)})^T * \delta^{(k+1)})\end{aligned}$$

由上式我们可以看到, 第 k 层神经元的误差项 $\delta^{(k)}$ 是由第 $k + 1$ 层的误差项乘以第 $k + 1$ 层的权重, 再乘以第 k 层激活函数的导数 (梯度) 得到的。这就是误差的反向传播。

2.4 计算 $\frac{\partial L(y, \hat{y})}{\partial W^{(k)}}$ 和 $\frac{\partial L(y, \hat{y})}{\partial b^{(k)}}$

$$\frac{\partial L(y, \hat{y})}{\partial W^{(k)}} = \frac{\partial L(y, \hat{y})}{\partial z^{(k)}} * \frac{\partial z^{(k)}}{\partial W^{(k)}} = \delta^{(k)} * (n^{(k-1)})^T$$

$$\frac{\partial L(y, \hat{y})}{\partial b^{(k)}} = \frac{\partial L(y, \hat{y})}{\partial z^{(k)}} * \frac{\partial z^{(k)}}{\partial b^{(k)}} = \delta^{(k)}$$

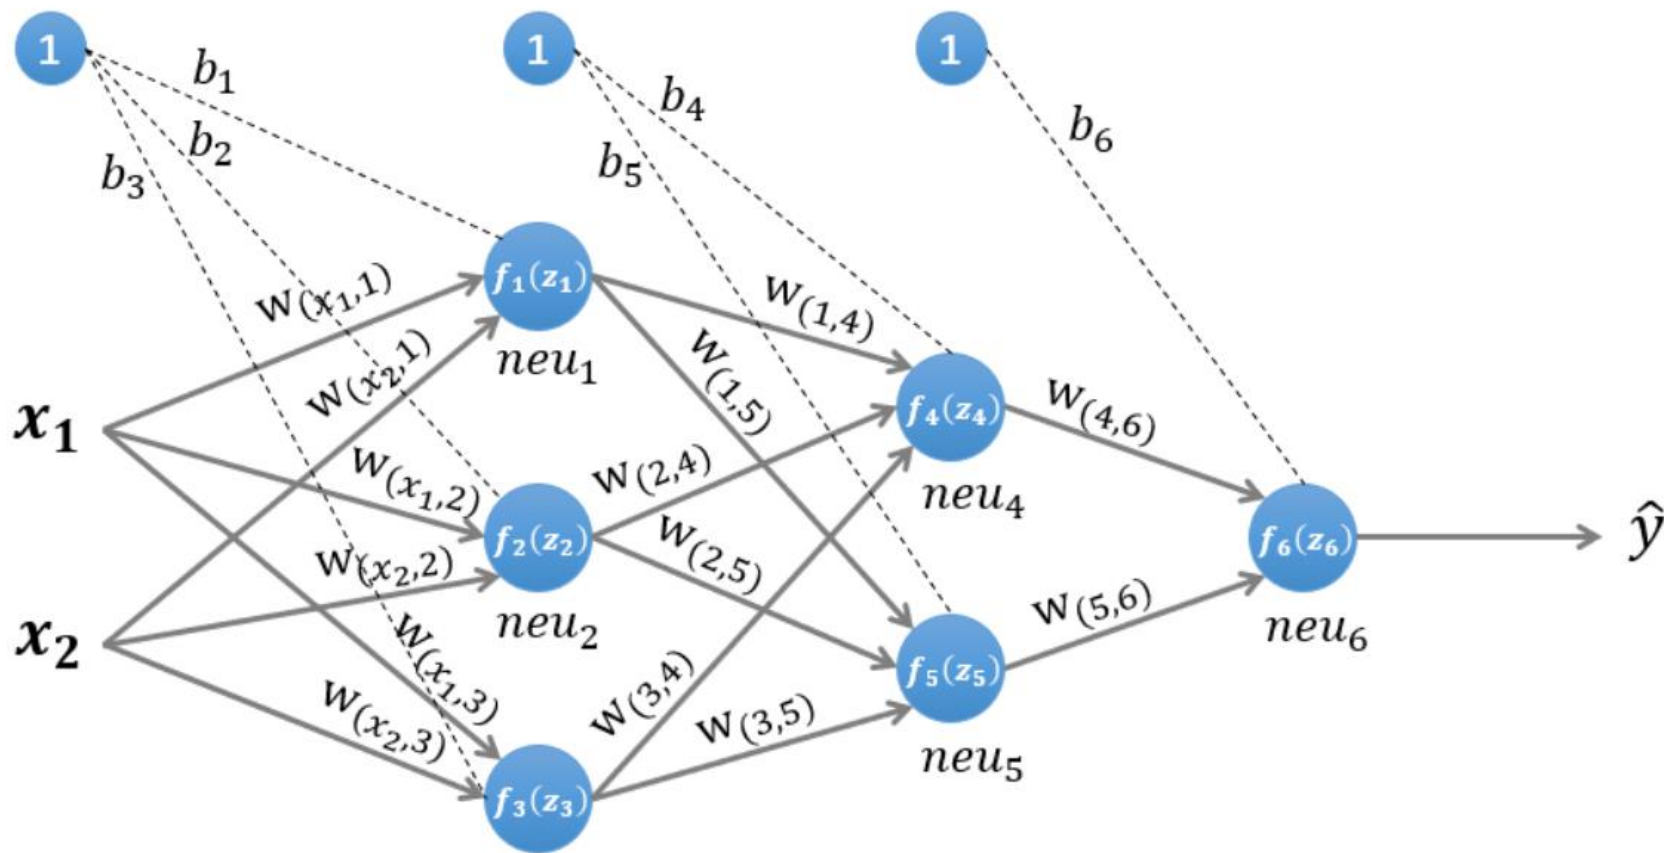
2.5 更新参数

$$W^{(k)} = W^{(k)} - \eta (\delta^{(k)} (n^{(k-1)})^T + W^{(k)})$$

$$b^{(k)} = b^{(k)} - \eta \delta^{(k)}$$

η 为学习率

例子



例子:

输入样本: $\mathbf{x} = [x_1 \ x_2]^T = [1 \ 2]^T$, 其真实类标为1

第一层网络参数:

$$W^{(1)} = \begin{bmatrix} w_{(x_1,1)}, w_{(x_2,1)} \\ w_{(x_1,2)}, w_{(x_2,2)} \\ w_{(x_1,3)}, w_{(x_2,3)} \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \\ 3 & 2 \end{bmatrix}, \quad b^{(1)} = [b_1, b_2, b_3]^T = [1, 2, 3]^T.$$

第二层网络参数:

$$W^{(2)} = \begin{bmatrix} w_{(1,4)}, w_{(2,4)}, w_{(3,4)} \\ w_{(1,5)}, w_{(2,5)}, w_{(3,5)} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 2 \\ 3 & 2 & 2 \end{bmatrix}, \quad b^{(2)} = [b_4, b_5]^T = [2, 1]^T.$$

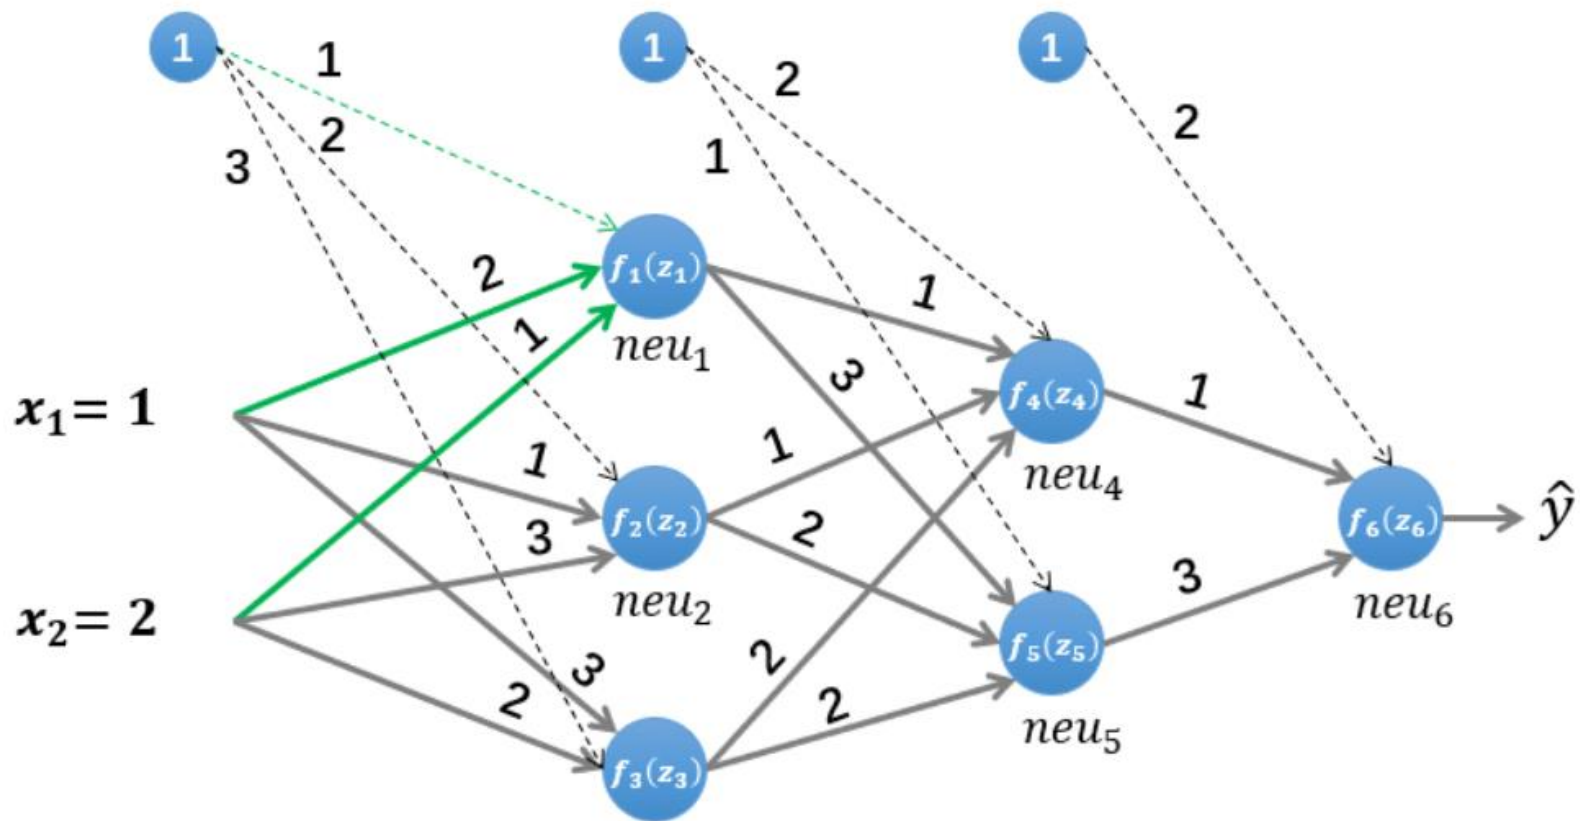
第三层网络参数:

$$W^3 = [w_{(4,6)}, w_{(5,6)}] = [1, 3], \quad b^{(3)} = [b_6] = [2].$$

假设所有的激活函数均为 Logistic 函数: $f^{(k)}(x) = \frac{1}{1+e^{-x}}$ 。使用均方误差函数作为损失函数:


$$L(y, \hat{y}) = E(y - \hat{y})^2.$$

为了方便求导, 我们将损失函数简化为: $L(y, \hat{y}) = \frac{1}{2} \sum (y - \hat{y})^2$ 。



1 正向传播

1.1 计算第一层隐含层



$$z_1 = w_{(x_1,1)} * x_1 + w_{(x_2,1)} * x_2 + b_1$$


$$= 2 * 1 + 1 * 2 + 1$$

$$= 5$$

$$f_1(z_1) = \frac{1}{1 + e^{-z_1}} = 0.993307149075715$$

1 正向传播

1.1 计算第一层隐含层



$$z_2 = w_{(x_1,2)} * x_1 + w_{(x_2,2)} * x_2 + b_2$$

$$= 1 * 1 + 3 * 2 + 2 = 9$$

$$f_2(z_2) = \frac{1}{1 + e^{-z_2}} = 0.999876605424014$$


$$z_3 = w_{(x_1,3)} * x_1 + w_{(x_2,3)} * x_2 + b_3$$

$$= 3 * 1 + 2 * 2 + 3 = 10$$

$$f_3(z_3) = \frac{1}{1 + e^{-z_3}} = 0.999954602131298$$

1 正向传播

1.2 计算第二层隐含层



$$z_4 = w_{(1,4)} * f_1(z_1) + w_{(2,4)} * f_2(z_2) + w_{(3,4)} * f_3(z_3) + b_4 \downarrow$$

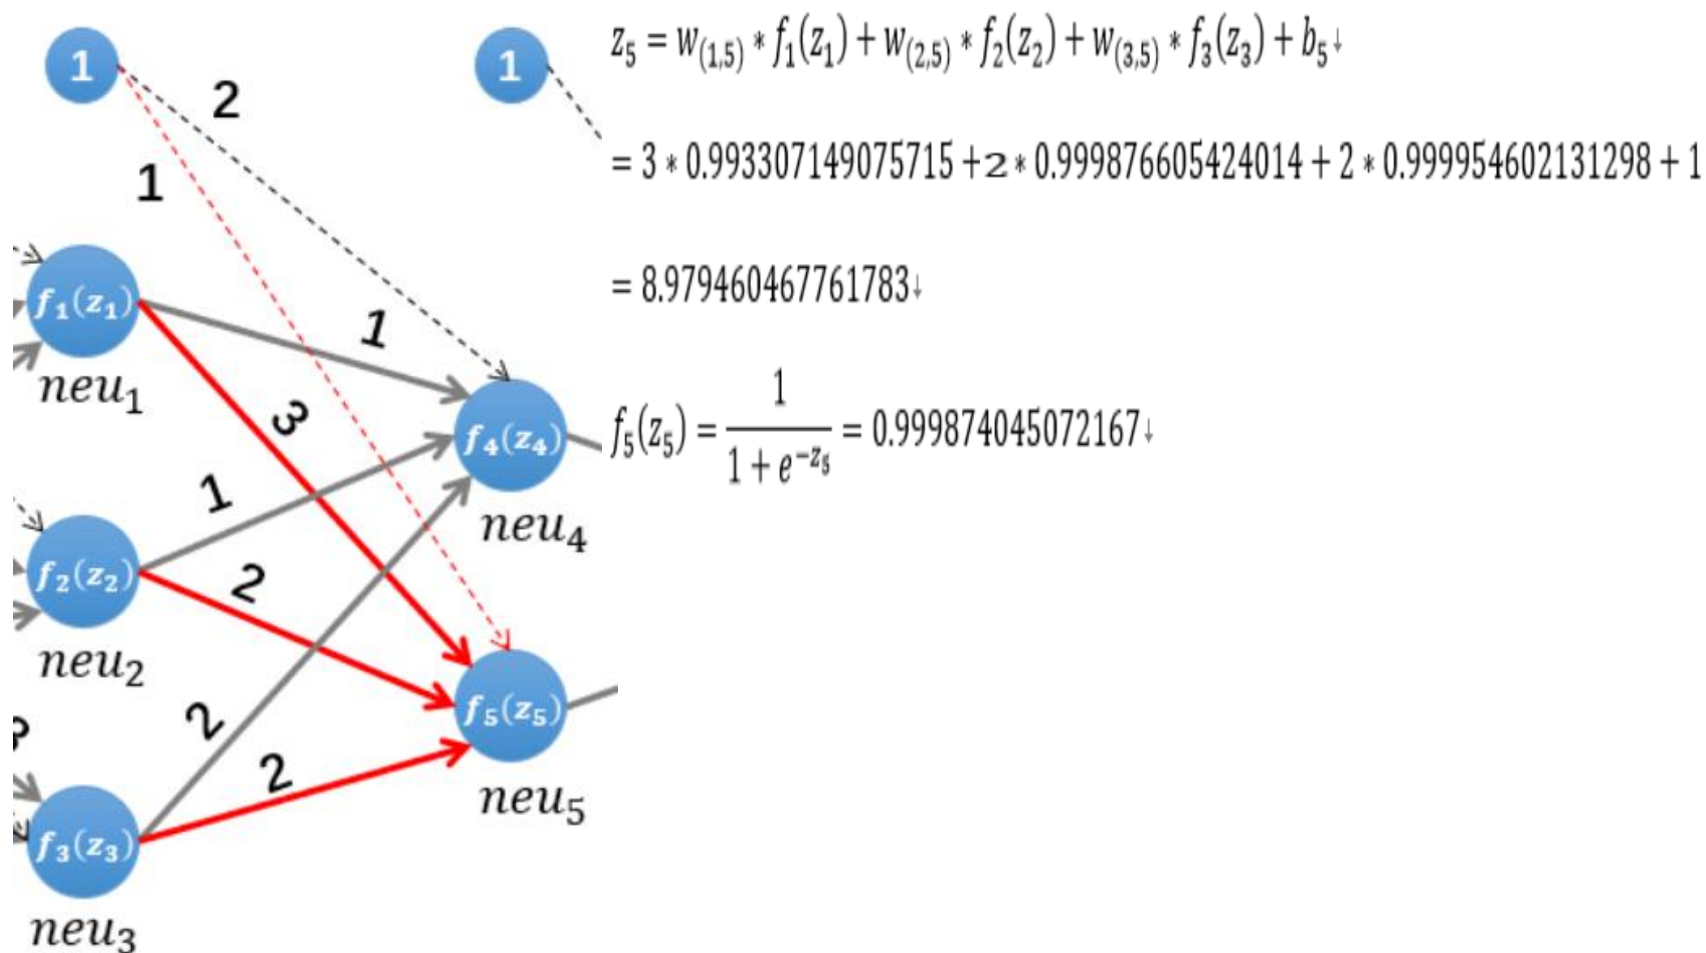
$$= 1 * 0.993307149075715 + 1 * 0.999876605424014 + 2 * 0.999954602131298 + 2 \downarrow$$

$$= 5.993092958762325 \downarrow$$

$$f_4(z_4) = \frac{1}{1 + e^{-z_4}} = 0.997510281884102 \downarrow$$


1 正向传播

1.2 计算第二层隐含层



1正向传播

1.3 计算输出层



$$z_6 = w_{(4,6)} * f_4(z_4) + w_{(5,6)} * f_5(z_5) + b_6 \\ = 1 * 0.997510281884102 + 3 * 0.9998404502167 + 2$$

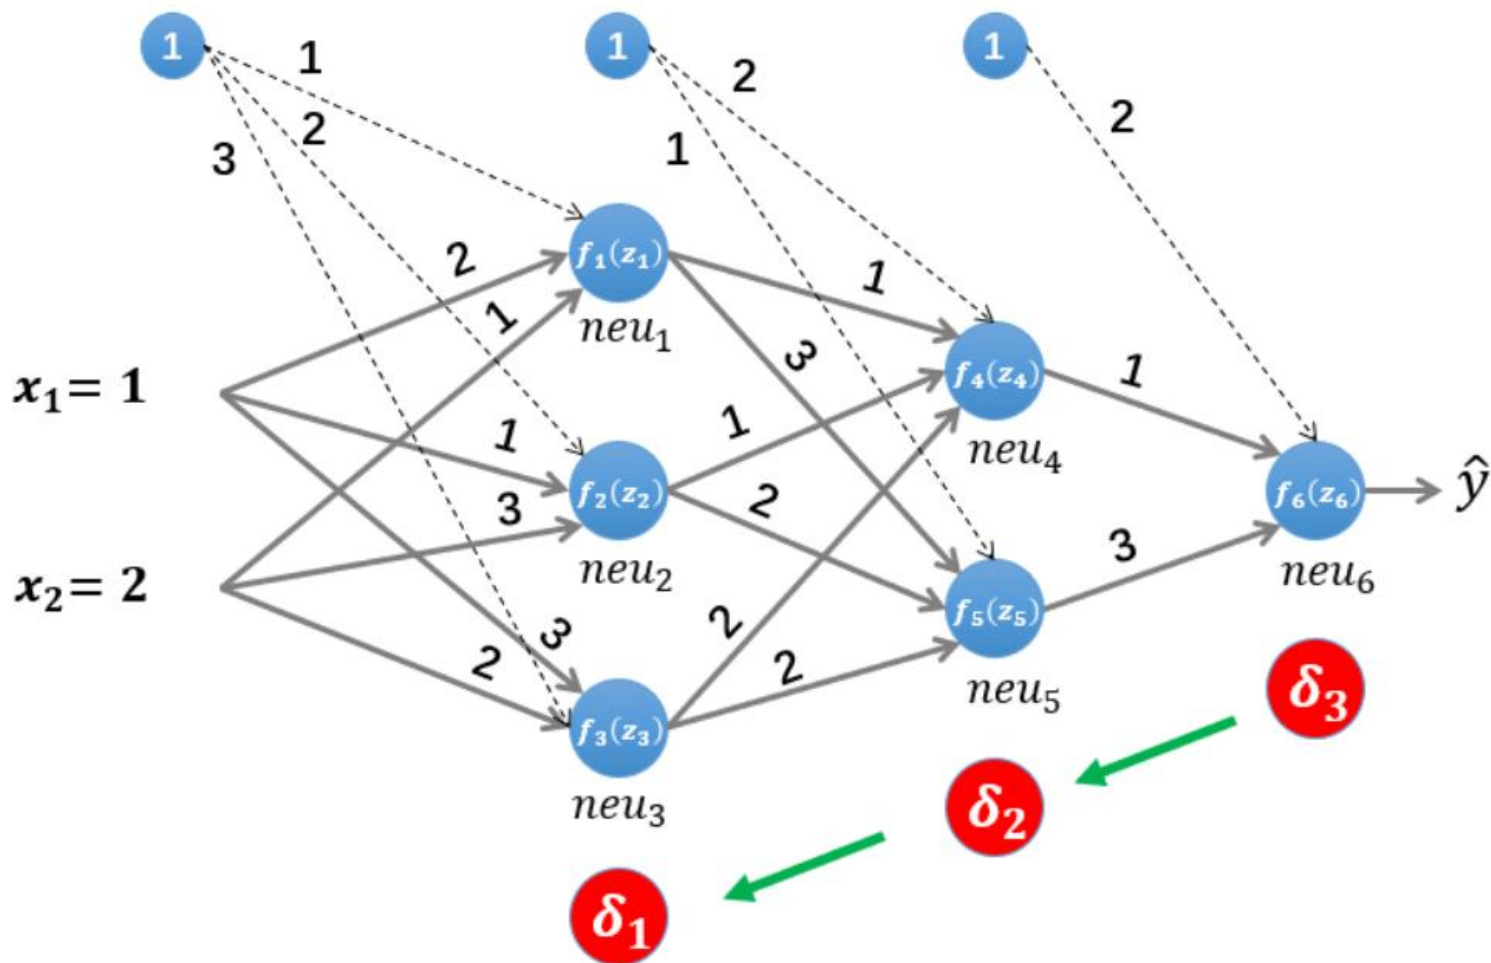
$$f_6(z_6) = \frac{1}{1 + e^{-z_6}} = 0.997520293823002$$

2 反向传播

2.1 计算神经网络误差

$$L = (y, \hat{y}) = \frac{1}{2} \sum (y - \hat{y})^2$$

$$y - \hat{y} = 1 - 0.997520293823002 = 0.002479706176998$$



2反向传播

2.1 计算输出层误差项

$$\begin{aligned}\delta_3 &= \frac{\partial L(y, \hat{y})}{\partial z^{(3)}} = \frac{\partial L(y, \hat{y})}{\partial n^{(3)}} * \frac{\partial n^{(3)}}{\partial z^{(3)}} = [-0.002479706176998] * f^{(3)'}(z^3) \\ &= [0.002473557234274] * [-0.002479706176998] \\ &= [-0.000006133695153]\end{aligned}$$

注：Logistic函数的求导公式

https://blog.csdn.net/qq_32768743/article/details/79118682

2反向传播

2.2 计算第二隐含层的误差项

$$\begin{aligned}\delta^{(2)} &= \frac{\partial L(y, \hat{y})}{\partial z^{(2)}} = f^{(2)'}(z^{(2)}) * ((W^{(3)})^T * \delta^{(3)}) \\&= \begin{bmatrix} f_4'(z_4) & 0 \\ 0 & f_5'(z_5) \end{bmatrix} * \left(\begin{bmatrix} 1 \\ 3 \end{bmatrix} * [-0.000006133695153] \right) \\&= \begin{bmatrix} 0.002483519419601 & 0 \\ 0 & 0.000125939063189 \end{bmatrix} * \begin{bmatrix} -0.000006133695153 \\ -0.000018401085459 \end{bmatrix} \\&= \begin{bmatrix} -0.000000015233151 \\ -0.000000002317415 \end{bmatrix}\end{aligned}$$

2反向传播

2.3 计算第一隐含层的误差项

$$\begin{aligned}\delta^{(1)} &= \frac{\partial L(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{z}^{(1)}} = f^{(1)'}(\mathbf{z}^{(1)}) * ((W^{(2)})^T * \delta^{(2)}) \\&= \begin{bmatrix} f_1'(z_1) & 0 & 0 \\ 0 & f_2'(z_2) & 0 \\ 0 & 0 & f_3'(z_3) \end{bmatrix} * ((W^{(2)})^T * \delta^{(2)}) \\&= \begin{bmatrix} 0.006648056670790 & 0 & 0 \\ 0 & 0.000123379349765 & 0 \\ 0 & 0 & 0.000045395807735 \end{bmatrix} \\&\quad * \left(\begin{bmatrix} 1 & 1 & 2 \\ 3 & 2 & 2 \end{bmatrix}^T * \begin{bmatrix} -0.000000015233151 \\ -0.000000002317415 \end{bmatrix} \right) \\&= \begin{bmatrix} -0.000000000147490 \\ -0.00000000002451 \\ -0.00000000001593 \end{bmatrix}\end{aligned}$$

3更新参数

3.1 更新第一隐含层的参数

$$W^{(1)} = W^{(1)} - 0.1 * (\delta^{(1)}(n^{(0)})^T + W^{(1)})$$

$$= \begin{bmatrix} 2 & 1 \\ 1 & 3 \\ 3 & 2 \end{bmatrix} - 0.1 * \left(\begin{bmatrix} -0.0000000000147490 \\ -0.0000000000002451 \\ -0.0000000000001593 \end{bmatrix} * [x_1 \quad x_2] + \begin{bmatrix} 2 & 1 \\ 1 & 3 \\ 3 & 2 \end{bmatrix} \right)$$

$$= \begin{bmatrix} 2 & 1 \\ 1 & 3 \\ 3 & 2 \end{bmatrix} - 0.1 * \left(\begin{bmatrix} -0.0000000000147490 \\ -0.0000000000002451 \\ -0.0000000000001593 \end{bmatrix} * [1 \quad 2] + \begin{bmatrix} 2 & 1 \\ 1 & 3 \\ 3 & 2 \end{bmatrix} \right)$$

$$= \begin{bmatrix} 2 & 1 \\ 1 & 3 \\ 3 & 2 \end{bmatrix} - 0.1 * \begin{bmatrix} 1.9999999999852510 & 0.9999999999705020 \\ 0.999999999997549 & 2.999999999995098 \\ 2.999999999998407 & 1.999999999996814 \end{bmatrix}$$

$$= \begin{bmatrix} 1.800000000014749 & 0.900000000029498 \\ 0.900000000000245 & 2.700000000000490 \\ 2.700000000000159 & 1.800000000000319 \end{bmatrix}$$

$$b^{(1)} = b^{(1)} - \eta \delta^{(1)}$$

$$= [1, 2, 3]^T - 0.1 * \begin{bmatrix} -0.0000000000147490 \\ -0.0000000000002451 \\ -0.0000000000001593 \end{bmatrix}$$

$$= \begin{bmatrix} 0.9999999999985251 \\ 1.999999999999755 \\ 2.999999999998411 \end{bmatrix}$$

3更新参数

3.2 更新第二隐含层和输出层的参数

方法同上